

KIT/BSQBD/KSQBD – noSQL systémy a Big Data

Titulní stránka / Moje kurzy / KIT/BSQBD/KSQBD (ZS, 2025/2026) / Zápočet, Zkouška / Ukázka popisu dat bez povinného Python scriptu

Navigace

- ▼ Titulní stránka
-  Nástěnka
- ▼ Moje kurzy
-  KIT/UPCUH (LS, 2025/2026)
-  JC/UPCUH (ZSiLS, 2025/2026)_2
-  JC/UPCUH (ZSiLS, 2025/2026)
-  KIT/BUSE (LS, 2025/2026)
-  KST/BPOG1 (LS, 2025/2026)
-  KIT/BBIS (LS, 2025/2026)
-  KIT/BMTA (ZS, 2025/2026)
-  KST/BCSH2 (ZS, 2025/2026)
-  KST/BMOSI (ZS, 2025/2026)
- ▼ KIT/BSQBD/KSQBD (ZS, 2025/2026)
- > Účastníci
-  Znamky
- ▼ Zápočet, Zkouška
-  Ukázka popisu dat bez povinného Python scriptu
-  KIT/BDAS2 (ZS, 2025/2026)
-  FES/BOZP poučení (ZS, 2025/2026)
-  KST/BCSH1 (LS, 2024/2025)
-  KIT/BRPP2 (LS, 2024/2025)
-  2025 – OS
-  KAM/BTEGR (LS, 2024/2025)
-  KST/BDATS (ZS, 2024/2025)
-  KST/BOOP (LS, 2024/2025)
-  KST/BPOG1 (LS, 2024/2025)
-  KIT/BSPWE (LS, 2024/2025)
-  KIT/BOPE2 (ZS, 2024/2025)_2
-  KIT/BOPE2 (ZS, 2024/2025)
-  2025 – PS1
-  KAM/BAMAT (ZS, 2024/2025)_KOMPAS
-  KAM/BAMAT (ZS, 2024/2025)
-  KIT/BZALG (ZS, 2024/2025)
-  2025 – IZ (ZS)
-  JC/IPAIH (LS, 2024/2025)
-  JC/IPAIG (ZS, 2024/2025)
-  JC/IPAIF (LS, 2023/2024)
-  Více...

Ukázka popisu dat bez povinného Python scriptu

Semestrální projekt - popis dat ukázka

Data pro zpracování pochází ze dvou různých zdrojů. Informace o letech pochází ze sítě OpenSky. Síť OpenSky je nezisková organizace, která sídlí ve Švýcarsku. Cílem této organizace je zvyšovat bezpečnost, spolehlivost a efektivitu využívání vzdušného prostoru tím, že umožňuje veřejnosti přístup k reálným datům o vzdušném provozu. Síť získává data sledováním automatického radiového vysílání každého letadla, které tak udává svoji pozici ve vzduchu viz <https://opensky-network.org/>

Data o letech tedy pochází ze sítě OpenSky, ale jsou ke stažení na webu Zenodo viz <https://zenodo.org/record/4485741#.YEOwRy3yquN> Na tomto webu se nachází data o letech od 1. 1. 2019 až do současnosti a budou dále aktualizována, dokud neskončí pandemie koronaviru. Z důvodu velkého objemu dat jsou data komprimována do formátu ".gz". Po rozbalení archivu získáme CSV soubor, který obsahuje data, která budeme zpracovávat.

Z důvodu obrovského množství dat v této datové sadě bylo potřeba data o letech vyfiltrovat pouze na lety, které začínaly nebo končily na letišti ve spojených státech amerických. Tento údaj byl zjištěn z druhého datového zdroje o letištích, který je popsán níže. Aby byl ještě více snížen datový dopad bylo z datasetu vyřazeno několik sloupců pro snížení celkové velikosti.

Struktura tohoto souboru je velmi jednoduchá. Soubor obsahuje 16 sloupců, které budou popsány dále. Přestože soubor obsahuje tolik sloupců neobsahuje sloupec, který by udával unikátní identifikátor záznamu.

Prvním sloupcem obsaženém v záznamech o letech je takzaný "callsign". Jedná se o identifikátor letu, který se zobrazuje letecké kontrole na radaru. Druhým sloupcem zdrojových dat je "number". Jedná se o komerční číslo letu, ale nemusí být vždy k dispozici. Síť OpenSky zjišťuje toto číslo pomocí veřejného API a callsign. Třetím sloupcem je "icao24". Jedná se o identifikátor transponderu tohoto letadla. Transponder je radiový vysílač, který vysílá jeho polohu, rychlost i výšku. Čtvrtým sloupcem je "registration", který obsahuje číslo letadla, které bývá napsáno na jeho ocase. Tento údaj není vždy dostupný. Pátým sloupcem je "typecode", který udává model letadla. Model letadla také nemusí být vždy dostupný. Šestým a sedmým sloupcem jsou "origin" a "destination". Tyto sloupce obsahují čtyři znakový ICAO identifikátor letiště, ze kterého letadlo vylételo a kam míří. Tyto údaje nemusí být vždy dostupné. Osmý a devátý sloupec je "firstseen" a "lastseen". Tyto sloupce obsahují časové razítko, kdy bylo letadlo poprvé nebo naposled spatřeno sítí OpenSky. Tento čas je udáván v UTC. Desátým sloupcem je "day". Obsahuje den kdy bylo letadlo naposled spatřeno sítí OpenSky. Tento údaj je také v UTC. Posledních 6 sloupců obsahuje údaje o tom kde byl let poprvé a naposled zaznamenán. Tyto sloupce tedy sledují zeměpisnou šířku a délku, ale také výšku letu letadla.

Ostatní data pochází z databáze OpenFlights. OpenFlights je nástroj, který umožňuje mapování vlastních letů po celém světě. Také umožňuje lety vyhledávat a zajímavě filtrovat. Automaticky počítá statistiky a umožňuje sdílení cest s přáteli nebo i s celým světem. Celý projekt je OpenSource a také veřejně sdílí svá data o letištích, leteckých společnostech a dalších k volnému použití, když je uveden zdroj a licence. Licence pro tyto data je takzvaná otevřená databázová licence (ODbL) a umožňuje nekomerční využití zdarma viz <https://openflights.org/>

Data o letištích tedy pochází z databáze OpenFlights viz <https://openflights.org/data.html> (Airport database) a jsou k dispozici ve formátu ".dat", ale v podstatě se jedná o CSV formát. Pro převedení do CSV stačí změnit koncovku souboru bez hlavičky v prvním řádku. Jednotlivé sloupce v rámci souboru jsou oddělené čárkou a je jich dohromady 14. Když není nějaký údaj dostupný zdrojový soubor obsahuje znak \N a tím označuje hodnotu jako prázdnou (null).

Prvním sloupcem v datech o letištích je "Airport ID". Jedná se o unikátní OpenFlights identifikátor tohoto letiště. Druhým sloupcem je "Name", který obsahuje jméno letiště. Také někdy může ještě obsahovat jméno města ve kterém se letiště nachází, ale není to podmínkou. Třetím sloupcem je "City". Tento sloupec obsahuje název města, kterému letiště slouží. Tento název může být trochu jiný než název města ve jméně letiště. Čtvrtým sloupcem je "Country" a obsahuje stát nebo teritorium, ve kterém se letiště nachází. Pátým sloupcem je "IATA" a jedná se o takzvaný IATA (International Air Transport Association - Mezinárodní sdružení leteckých dopravců) kód letiště. Tento kód má vždy tři znaky nebo není dostupný. Šestým sloupcem je "ICAO", jedná se o ICAO kód letiště. Tento kód také nemusí být vždy dostupný a pomocí něj budou napojeny údaje o letištích na data o letech. Sedmým a osmým sloupcem jsou "latitude" a "longitude". Jedná se samozřejmě o zeměpisnou délku a šířku, která udává polohu letiště ve světě. Je udávána ve stupních, a to většinou na šest desetinných míst. Když zeměpisná šířka nabývá záporné hodnoty, tak se jedná o jih. Kladné hodnoty patří severu. U zeměpisné délky záporné hodnoty určují západ a kladné hodnoty určují východ. Devátým sloupcem je "altitude" a jedná se o nadmořskou výšku a je udávána ve stopách. Desátým sloupcem je "Timezone" a udává o kolik se v daném místě čas liší od UTC. Může obsahovat desetinná čísla - například Indie je posunutá oproti UTC o 5,5 hodin. Jedenáctým sloupcem je "DST" a jedná se o údaj o letním čase. Může obsahovat tyto hodnoty: E (Evropa), A (Amerika nebo Kanada), S (Jižní amerika), O (Austrálie), Z (Nový zéland), N (žádný) nebo U (neznámý). Tato hodnota je ale pouze přibližná a na úrovni státu. Pochází z dat z roku 2009 a některé země jsou označeny špatně. Dvanáctým sloupcem je "Type" a jedná se o typ zastávky. Tento sloupec je tu proto, že databáze OpenFlights obsahuje i data o vlakových stanicích a přístavech. V datech použitých pro tuto práci bude typ vždy nabývat hodnoty "airport". Třináctým a posledním sloupcem je "Source". Tento sloupec udává odkud pochází data o tomto letišti. Může nabývat následujících hodnot: "OurAirports" (data z ourairports.com), "User" (údaje nahrané uživateli tohoto nástroje) nebo "Legacy" (stará data nemapovaná na OurAirports). Pro další práci budou využita jen data s hodnotou "OurAirports".

Poslední datová sada představuje data o leteckých společnostech. Tyto data také pochází z databáze OpenFlights viz : <https://openflights.org/data.html> a stejně jako údaje o letištích jsou uložena ve formátu ".dat", ale je možné je převést na CSV formát stejným způsobem. Tato datová sada obsahuje 8 sloupců.

Prvním sloupcem v této datové sadě je "Airline ID" a jedná se o unikátní identifikátor letecké společnosti v rámci databáze OpenFlights. Druhým sloupcem je "Name" a jedná se o jméno letecké společnosti. Třetím sloupcem je "Alias" a jedná se o alias letecké společnosti. Například All Nippon Airways je běžně znám jako "ANA". Čtvrtým sloupcem je "IATA" a jedná se o IATA kód letecké společnosti. Tento kód nemusí být vždy k dispozici. Pátým sloupcem je "ICAO". Jedná se o 3 znakový identifikátor letecké společnosti a také nemusí být vždy dostupný. Podle tohoto identifikátoru bude v rámci této práce spojován let s danou leteckou společností. Šestým sloupcem tedy datové sady je "Callsign", který nebude v rámci této práce překládán. Sedmým sloupcem je "Country" a jedná se o název země ze které letecká společnost pochází. Posledním, sedmým sloupcem je "Active" a obsahuje "Y" pokud je letecká společnost v provozu a nebo "N" pokud není. Tato hodnota ale není spolehlivá. A to hlavně u velkých společností, které přestaly létat před dlouho dobou, ale jejich IATA kód nebyl přidělen jiné společnosti (například Ansett/AN bude nesprávně zobrazen jako aktivní).

Rozsah použitých dat

Z důvodu velmi vysokého objemu dat o letech letadel ve vybraný měsíc je nutné data vyfiltrovat, aby obsahovala pouze data o letech začínajících nebo končících na amerických letištích. Také byly vyřazeny údaje o letech, které neměly údaj o obou letištích (start a cíl) a také o letech, které začínaly a končily na stejném letišti. Dále bude odstraněno několik sloupců, které nejsou důležité.

Původní data o letech v dubnu 2019 obsahuje 2 375 102 záznamů. Po veškerém filtrování je snížen počet záznamů z roku 2019 na 531 572. Původní data o letech v dubnu roku 2020 obsahují 842 906 záznamů a po provedení filtrování jich je pouhých 322 638.

V tabulce letů budou vynechány tyto sloupce:

- Firstseen,
- Lastseen,
- Latitude_1,
- Longitude_1,
- Altitude_1,
- Latitude_2,
- Longitude_2,
- Altitude_2.

V tabulce leteckých společností nebudou vynechán žádný sloupec. Původní rozsah datové sady je 6 162, ale z důvodu, že některé jejich identifikátory obsahují cizí znaky (především azbuku), tak bylo do databáze importováno pouze 5 744. Azbuka způsobovala problémy a identifikátor letiště by se nevešel do sloupce pevně dané velikosti CHAR(2). Jelikož se další kroky budou zaměřovat na lety v rámci USA autor usoudil, že je lepší omezena pouze data dle jejich definice.

V tabulce letů budou vynechány sloupce „Type“ a „Source“, protože oba sloupce obsahují pouze jednu hodnotu, která se pořád opakuje. Řádky, ale budou importovány všechny. Tudiž tato práce pracuje se 7 698 letišti po celém světě.

Analýza

Z nalezených dat lze provést analýzu letů před koronavirovou krizí a během ní, konkrétně povede ke srovnání letů v dubnu 2019 s lety z dubna 2020. Předpoklad je, že v roce 2019 bylo realizováno více letů, protože svět ještě nebyl zasažen pandemií COVID-19. Z dat lze zjistit, zda se změnil počet obsluhovaných letišť nebo leteckých společností. Pokud tento počet klesnul, je šance že za tuto změnu může koronavirus a omezení cestování ve světě.

Cílem je tedy analyzovat četnost letů, průměrnou uletěnou vzdálenost za určité období nebo také počty navštívených letišť. Zároveň zjistit, zda se změnilo nejčastější destinace a letecké společnosti. V neposlední řadě nás zajímá, zda se liší průměrný počet uletěných kilometrů ve všední dny oproti víkendům. Data využitá k analýze letů ze sítě OpenSky, která má více než 2500 členů. Tato síť sleduje lety již od 1. 1. 2019 a bude v tom pokračovat až do konce pandemie koronaviru. Z důvodu velkého množství dat (až stovky MB měsíčně) o letech sledovaných touto sítí bude analýza omezena pouze na lety, které začínají nebo přistávají na amerických letištích. Tato analýza nevezníka pro žádnou určitou společnost, ale bude sledovat všechny letecké společnosti, aby dokázala dopad COVID-19 na letecké společnosti a počty letů ve světě. Výše zmíněná data o letech ze sítě OpenSky budou propojena s dvěma dalšími datasety, aby bylo možné provést správnou analýzu. Data o letech budou propojena s daty o letištích, která pochází z databáze OpenFlights. Tato databáze obsahuje data o více než 10 000 letištích z celého světa. Posledním použitým datasetem jsou údaje o leteckých společnostích, které také pocházejí z OpenFlights a obsahují více než 5 000 leteckých společností. Pro správné propojení dat bude nutné nejdříve transformovat, a to převážně kvůli správnému napojení na časovou osu nebo letecké společnosti. Při spojování letů a letišť bude využit čtvrtý znakový ICAO1 identifikátor, který jednoznačně identifikuje letiště. V letištích se nachází pod sloupcem ICAO a v údajích o letech se jedná o zdrojové a cílové letiště. Při spojování letů s leteckými společnostmi bude využit sloupec callsign v údajích o letech, jehož součástí jsou jako první tři znaky údaje o letecké společnosti. Přesnější se jedná o její ICAO kód, který se nachází i v datech leteckých společností. Správnost zpracovávaných dat z našeho pohledu můžeme ověřit tím, že nedovolíme lety z jednoho letiště na to samé (vzdálenost 0 kilometrů nebo menší). Také nedovolíme údaje o letech, u kterých není známé zdrojové nebo cílové letiště.

Naposledy změněno: neděle, 8. února 2026, 16.44

→ Šablona

Přejít na...

Kde čerpat data k semestrálnímu projektu? ➡

 [Kontaktujte podporu stránek](#)

Jste přihlášení jako [Denys Tkach](#) ([Odhlásit se](#))
[KIT/BSQBD/KSQBD \(ZS, 2025/2026\)](#)

[Souhrn uchovávaných dat](#)

[Stáhněte si mobilní aplikaci](#)