KIT/BSQBD/KSQBD - noSQL systémy a Big Data

Navigace
- Titulní stránka
  - Nástěnka
  - Moje kurzy
    - JC/UPCUH (LS, 2025/2026)
    - JC/UPCUH (ZSiLS, 2025/2026)_2
    - JC/UPCUH (ZSiLS, 2025/2026)
    - KIT/BUSE (LS, 2025/2026)
    - KST/BPOG1 (LS, 2025/2026)
    - KIT/BBIS (LS, 2025/2026)
    - KIT/BMTA (ZS, 2025/2026)
    - KST/BCSH2 (ZS, 2025/2026)
    - KST/BMOSI (ZS, 2025/2026)
    - KIT/BSQBD/KSQBD (ZS, 2025/2026)
      - Účastníci
      - Známky
      - Zápočet, Zkouška
        - ZADÁNÍ zápočtového projektu
    - KIT/BDAS2 (ZS, 2025/2026)
    - FES/BOZP poučení (ZS, 2025/2026)
    - KST/BCSH1 (LS, 2024/2025)
    - KIT/BRPP2 (LS, 2024/2025)
    - 2025 – OS
    - KAM/BTEGR (LS, 2024/2025)
    - KST/BDATS (ZS, 2024/2025)
    - KST/BOOP (LS, 2024/2025)
    - KST/BPOG1 (LS, 2024/2025)
    - KIT/BSPWE (LS, 2024/2025)
    - KIT/BOPE2 (ZS, 2024/2025)_2
    - KIT/BOPE2 (ZS, 2024/2025)
    - 2025 – PS1
    - KAM/BAMAT (ZS, 2024/2025)_KOMPAS
    - KAM/BAMAT (ZS, 2024/2025)
    - KIT/BZALG (ZS, 2024/2025)
    - 2025 – IZ (ZS)
    - JC/IPAIH (LS, 2024/2025)
    - JC/IPAIG (ZS, 2024/2025)
    - JC/IPAIF (LS, 2023/2024)
    - Více...

ZADÁNÍ zápočtového projektu

Semestrální projekt - obecné informace & obhajoba

Obecné informace k semestrální práci

1. **Semestrální práci zpracovává každý student individuálně.**
2. **Semestrální práce se skládá z:**
   1. **Funkčního řešení, které musí být nasazené na přidělený server pro kontrolu semestrální práce.**
   2. **Dokumentace.**
   3. **Povinných příloh k dokumentaci.**
   4. Ostatních nepovinných příloh.
3. **Minimální rozsah dokumentace k semestrální práci není stanoven**, ovšem semestrální práce musí mít zpracované jednotlivé části s dostatečnou hloubkou, **doporučený rozsah** je tak stanoven na **10-30 stran od Úvodu k Závěru.**
   - Do doporučeného rozsahu nejsou započteny strany, kde obrázek, tabulka nebo jakákoliv jiná ilustrace tvoří půl strany, apod. a dále nejsou započteny přílohy k dokumentaci semestrální práce.
4. **Je nutné dodržet povinné části semestrální práce a dále specifika vybraného tématu, nelze zpracovat pouze vybrané části semestrální práce, v tom případě nebude semestrální projekt obhajitelný.**
5. Práce musí být vlastním dílem autora, jinak nebude uznána (kontrola plagiátorství), v práci je nutné uvést veškeré použité zdroje a nástroje.

Obhajoba

- **Obhajoba semestrální práce je povinná** a koná se dle vypsaných termínů ve STAGu nebo případně po individuální domluvě s vyučující**, práce není uznána pouhým odevzdáním.**
  - Na obhajobu je nutné dostavit se včas a ideálně s mírnou časovou rezervou, jelikož uvítám pokud se ostatní studující zúčastní co největšího počtu prezentací obhajob semestrálních prací.
- **Na obhajobu nevytvářejte žádnou prezentaci ve formátu PPTX, apod.**, budete používat odevzdanou semestrální práci tedy funkční řešení, dokumentaci k semestrální práci včetně příloh, tedy celý ZIP, který jste odeslali.
- **Prezentace bude cca na 15 minut** - předvedení stěžejních částí, zajímavostí ze zadaného tématu, čím je vaše práce výjimečná a co naopak nesplňuje.
- **Při obhajobě je nutné přesně vědět, jak funguje odevzdané řešení, a to z pohledu architektury, datových toků, jednotlivých dotazů apod., vše musí být reprodukovatelné/spustitelné. Před obhajobou si celé řešení na svém zařízení spusťte, ať časově nenarušujete okénko určené pro další/ho prezentující/ho, tzn. na obhajobu si student ideálně přinese vlastní zařízení (notebook), kde bude mít své řešení plně spuštěné a které bude prezentovat, pokud to není možné, pak řešení spustí na počítači v učebně a své řešení předvede na něm.**
- Následují **otázky vyučující cca 5-10 minut**.

Volba tématu semestrální práce

Student si vybírá z níže uvedených témat:

1. NoSQL databáze klíč-hodnota - Redis
2. NoSQL databáze dokumentová - MongoDB
3. NoSQL databáze sloupcově orientované - Apache Cassandra
4. The Elastic Stack (ELK)

Semestrální projekt - zadání - pokyny

Pro téma 1,2 a 3 platí následující povinné body semestrální práce, které řádně popište v dokumentaci:

- **ÚVOD**
  - Tato kapitola odpovídá na otázky:
    - Jaké téma semestrální práce popisuje?
    - Co vše se čtenář v seminární práci dozví – oblasti, technologie, případové studie, apod?
    - Co není součástí semestrálního projektu, ale vzhledem k tématu by mohlo být?
    - Nezapomeňte uvést verzi databáze, se kterou pracujete, dodržujte princip, že volíte maximálně tři verze zpětně od aktuální (ne major, tzn. např. u MongoDB nesmí být použita starší verze než 8.0.0., u Redis nesmí být starší verze než 8.2, atd.).
    - Nezapomeňte uvést zvolený/é oficiální obrazy z Docker Hub (můžete použít i bitnami obraz) a odůvodnění výběru, např. u Redisu je nutné, abyste měli funkční RedisInsight, Redis Stack Server, u MongoDB je vhodné, abyste měli kontejner s MongoCompass (web) - obraz z docker hub: haohanyang/compass-web, apod. Není chybou máte-li řešení postavené na vlastním Dockerfile.
- **1. ARCHITEKTURA**
  - Tato kapitola podrobně popisuje, jak jste provedli nasazení NoSQL databáze, proveďte a uveďte, jak konkrétně jste vybranou databázi nasadili a nastavili v rámci clusteru a jak ji využíváte, tato kapitola musí obsahovat následující podkapitoly:
  - 1.1. Schéma a popis architektury.
    - Vytvořte schéma architektury a vložte jako obrázek např. pomocí draw.io.
    - Podrobně architekturu popište, je nutné minimálně odpověď na tyto otázky:
      - Jak vypadá architektura Vašeho řešení a proč?
      - Jak se případně liší od doporučeného používání a proč?
  - 1.2.Specifika konfigurace
  - Podrobně popište specifikaci Vaší konfigurace. Tato kapitola musí obsahovat následující podkapitoly:
    - 1.2.1. CAP teorém
      - Uveďte, jaké garance Brewerova CAP teorému splňuje Vaše řešení?
      - Uveďte, proč právě tyto garance jsou pro Vaše řešení dostačující?
      - Uveďte řádný popis.
    - 1.2.2. Cluster
      - Minimálně 1.
      - Uveďte kolik clusterů používáte a proč?
      - Uveďte řádný popis.
    - 1.2.3. Uzly
      - Minimálně 3.
      - Uveďte kolik nodů používáte a proč?
      - Uveďte řádný popis.
    - 1.2.4. Sharding/Partitioning
      - Minimálně 3.
      - Uveďte, jak používáte sharding/partitioning?
      - Uveďte, zda používáte pro své řešení indexy a např. i sekundární indexy a proč je považujete za dostačující vzhledem k použitým datům (objem, typ dotazů, rozložení zátěže).
      - Uveďte řádný popis.
    - 1.2.5. Replikace
      - Minimálně 3.
      - Uveďte kolik replikací používáte a proč je považujete za dostačující vzhledem k použitým datům a požadované dostupnosti?
      - Uveďte řádný popis.
    - 1.2.6. Perzistence dat
      - Minimálně 3.
      - Uveďte, jakým způsobem řeší Vaše databáze perzistenci dat?
      - Uveďte, jak pracujte s primární i sekundární pamětí.
      - Uveďte, jak načítáte a ukládáte data.
      - Uveďte řádný popis.
    - 1.2.7. Distribuce dat
      - Z předešlých kapitol vše shrňte a uveďte, jak se data rozdělují, jak je replikujete, jak konkrétně u Vašeho řešení probíhá celková distribuce dat pro zápis/čtení.
      - Uveďte řádný popis - textový popis + screeny + popis uvádějící například skript, který provádí automatické rozdělení dat (pozor na příliš velkou výchozí velikost chunk), počty záznam na jednotlivých uzlech (count),...
    - 1.2.8. Zapezpečení
      - Uveďte, jakým způsobem jste vyřešili zabezpečení databáze a proč?
      - Minimálně je požadována autentizace a autorizace.
      - Upozornění: V případě MongoDB je nutné mít keyfile (ne fixní).
- **2. FUNKČNÍ ŘEŠENÍ**
  - Tato kapitola obsahuje popis návod na zprovoznění funkčního řešení a popis jeho struktury.
  - 2.1. Struktura
    - Popište adresářovou strukturu Vašeho řešení a jednotlivé soubory, docker-compose.yml popište důkladně samostatně v kapitole 2.1.1.
    - 2.1.1. docker-compose.yml
      - Uveďte řádný popis vytvořeného docker-compose.yml - jaké služby spouští, jaké porty, volumes, proměnné prostředí, závislosti a inicializační skripty, atd.
  - 2.2. Instalace
    - Podrobně popište, jak zprovoznit Vaše řešení.
    - Řešení je nutné vytvořit tak, aby využívalo docker a **spuštění probíhalo maximálně automatizovaně pomocí docker-compose.yml, tzn. že docker-compose.yml odkazuje na veškeré skripty, se kterými pracuje a pro zprovoznění není nutné provádět manuální spuštění pomocných skriptů.**
    - **V rámci docker-compose.yml využijte automatické spuštění skriptů poté co se vám spustí kontejnery viz například https://www.baeldung.com/ops/docker-compose-run-script-on-start**
- **3. PŘÍPADY UŽITÍ A PŘÍPADOVÉ STUDIE**
  - Popište pro jaké účely (případy užití) ja daná NoSQL databáze vhodná.
  - Uveďte, pro jaký účel (případ užití) jste si danou databázi zvolili a proč? K čemu Vaše řešení slouží? O jaký případ užití se jedná?
  - Uveďte, proč jste nezvolili jinou NoSQL databázi vzhledem k účelu?
  - Vyhledejte a popište 3 případové studie spojené s vybranou NoSQL databází.
  - Rozsah každé případové studie musí být alespoň 1/2 A4.
- **4. VÝHODY A NEVÝHODY**
  - Popište, jaké výhody a nevýhody má daná NoSQL databáze.
  - Uveďte, jaké výhody a nevýhody má Vaše řešení a proč?
- **5. DALŠÍ SPECIFIKA**
  - Popis specifických vlastností řešení, pokud nejsou použity žádná specifika, pak uveďte, že vaše řešení je použito jak je doporučeno a nemá vlastní specifika (nic mu nechybí a ani mu nic nepřebývá).
- **6. DATA**
  - Použijte libovolné **3 propojitelné datové soubory (ideálně z jedné kolekce), kdy jeden soubor obsahuje alespoň 5 tis. záznamů, doporučená šíře datového souboru je kolem 10-ti sloupců, např. viz https://www.kaggle.com/datasets/samyakrajbayar/streaming-platform-comprehensive-dataset?select=README.md**
  - Popis dat bude ve velké míře **zpracován pomocí knihoven jazyka Python** a dále bude doplněn dovysvětlujícími texty.
  - Jaká je distribuce shardů/slotů/partitions/tokenů a počet chunků pro daná data?
  - Jaká je velikost jednotlivých chunků/partitions?
  - Jaký je replication lag na secondary uzlech v shardech, consistency level (cassanra)?
  - Jaký je počet záznamů a velikost na shardu/uzlu?
  - Uveďte:
    - S jakými typy dat Vaše databáze pracuje, jakého jsou formátu a jak s nimi databáze nakládá?
    - Proč jste nezvolili další možné datové struktury pro Vaši databázi?
    - S kolika daty Vaše databáze bude pracovat? Jakého rozsahu jsou ukázková data?
    - Kolik obsahují prázdných hodnot?
    - Jaké úpravy jste s daty prováděli a proč?
    - Jaký je zdroj dat? Uveďte URL adresu.
    - Pomocí skriptů v Python s využitím knihoven Pandas, Numpy, apod. data popište a proveďte základní analýzu dat (základní statistiky - počty, prázdná pole, suma, průměr, grafické zobrazení, apod.
- **7. DOTAZY**
  - Uveďte a popište **30 NETRIVIÁLNÍCH různých navazujících příkladů včetně řešení (všechny tři datasety popisují jedno téma) a podrobného vysvětlení jednotlivých příkazů.**
    - NETRIVIÁLNÍ dotaz je například dotaz využívající v MongoDB aggregate a zároveň unwind a zároveň group a zároveň sort nebo například aggregate a zároveň lookup a zároveň match a zároveň project nebo aggregate a zároveň unset a zároveň ....
    - Příkazy řádně okomentujete tzn., že každý příkaz zkopírujete z konzole a u každého příkazu uvedete, jaké je jeho obecné chování a jak konkrétně pracuje s daty ve vašem případě a řeší konkrétní úlohu**.**
    - **Předpoklad je takový, že budete mít příkazy z různých kategorií např.:**
      - **"práce s daty" - insert, update, delete, merge**
      - **"agregační funkce",**
      - **"konfigurace",**
      - **"nested (embedded) dokumenty",**
      - **"indexy"**
      - **takových kategorií je požadováno alespoň 5, kdy u každé "kategorie" uvedete alespoň 6 příkazů.**
  - Každý dotaz musí vracet nějaká data.
  - **Každý dotaz musí vracet různá data. Nelze, aby stejná data vracelo více dotazů.**
  - Dle zvoleného typu databáze využijte i možnost práce s clusterem, replikačním faktorem a shardingem.
  - Pokuste se například (mimo jiné) nasimulovat výpadek některého z uzlů a popište možnosti řešení.
  - Upozornění: V případě MongoDB je nutné mít validační schéma.
- **ZÁVĚR**
  - V závěru pochvalně i kriticky zhodnoťte Vaši semestrální práci, popište hloubku zpracování. Shrňte k jakým závěrům jste došli, co je možné s Vaším řešením vykonávat, apod.
- **ZDROJE A NÁSTROJE**
  - Uveďte řádně všechny zdroje a nástroje, se kterými jste pracovali, abecedně seřazené, a to včetně použitých nástrojů.
- **PŘÍLOHY DOKUMENTACE**
  - **Data**
  - **složka** pojmenovaná Data, která obsahuje:
    - obsahuje minimálně 3 datasety
    - obsahuje Python skript (JupyterLab)
  - **Dotazy**
  - **složka** pojmenovaná Dotazy, která obsahuje:
    - 1 soubor se všemi dotazy, kdy každý dotaz obsahuje zadání v přirozeném jazyce a řešení v příslušeném jazyce vybrané NoSQL databáze
  - **Funkční řešení**
  - **Složka** pojmenovaná Funkční řešení, která obsahuje:
    - docker-compose.yml
    - skripty nutné pro zprovoznění
    - případně další složky a soubory nutné pro zprovoznění řešení

Pro téma 4 (The Elastic Stack – ELK) platí následující povinné body semestrální práce, které řádně popište v dokumentaci:

- **ÚVOD**
  - Tato kapitola odpovídá na otázky:
    - Jaké téma semestrální práce popisuje?
    - Co vše se čtenář v semestrální práci dozví – oblasti, technologie, případové studie, apod.?
    - Co není součástí semestrálního projektu, ale vzhledem k tématu by mohlo být?
    - Nezapomeňte uvést verze jednotlivých komponent ELK stacku (Elasticsearch, Logstash, Kibana), se kterými pracujete. Dodržujte princip, že volíte maximálně tři verze zpětně od aktuální (ne major, tzn. např. u Elasticsearch nesmí být použita starší verze než 8.0.0., u ostatních komponent obdobně).
    - Nezapomeňte uvést zvolený/é obrazy z Docker Hub a odůvodnění výběru, např. oficiální obrazy elasticsearch, logstash, kibana včetně důvodu (podpora security, verze, dostupná dokumentace, apod.).
- **1. ARCHITEKTURA**
-
  - Tato kapitola podrobně popisuje, jak jste provedli nasazení ELK stacku, uveďte, jak konkrétně jste jednotlivé komponenty (Elasticsearch, Logstash, Kibana, případně Beats) nasadili a nastavili v rámci clusteru a jak je využíváte. Tato kapitola musí obsahovat následující podkapitoly:
  - 1.1. Schéma a popis architektury
    - Vytvořte schéma architektury a vložte jej jako obrázek, např. pomocí draw.io.
    - Podrobně architekturu popište, je nutné minimálně odpovědět na tyto otázky:
      - Jak vypadá architektura Vašeho řešení a proč? (např. kolik Elasticsearch nodů, kde běží Logstash, jak je připojena Kibana, odkud přichází logy/data).
      - Jak se případně liší od doporučeného používání a proč? (např. zjednodušení pro účely semestrální práce a proč?).
  - 1.2. Specifika konfigurace
  - Podrobně popište specifikaci Vaší konfigurace. Tato kapitola musí obsahovat následující podkapitoly:
    - 1.2.1. CAP teorém
      - Uveďte, jaké garance Brewerova CAP teorému splňuje Vaše řešení (např. jak se v kontextu Elasticsearch projevuje dostupnost a tolerance rozdělení).
      - Uveďte, proč právě tyto garance jsou pro Vaše řešení dostačující.
      - Uveďte řádný popis.
    - 1.2.2. Cluster
      - Minimálně 1.
      - Uveďte, kolik clusterů Elasticsearch používáte a proč?
      - Uveďte řádný popis.
    - 1.2.3. Uzly
      - Minimálně 3.
      - Uveďte, kolik nodů (uzlů) Elasticsearch používáte, jaké mají role (master/data/ingest) a proč jste zvolili právě takové rozdělení.
      - Uveďte řádný popis.
    - 1.2.4. Sharding/Partitioning
      - Minimálně 3.
      - Uveďte, jak používáte sharding/partitioning?
      - Uveď, zda používáte pro své řešení indexy a např. i sekundární indexy a proč je považujete za dostačující vzhledem k použitým datům (objem, typ dotazů, rozložení zátěže).
      - Uveďte řádný popis.
    - 1.2.5. Replikace
      - Minimálně 3.
      - Uveďte, kolik replik používáte a proč je považujete za dostačující vzhledem k použitým datům a požadované dostupnosti.
      - Uveďte řádný popis.
    - 1.2.6. Perzistence dat
      - Minimálně 3.
      - Uveďte, jakým způsobem řeší Vaše řešení perzistenci dat v Elasticsearch (ukládání indexů na disk, práce s primární a sekundární pamětí).
      - Uveďte, jak probíhá načítání a ukládání dat (indexace, refresh intervaly, segmenty).
      - Uveďte řádný popis.
    - 1.2.7. Distribuce dat
      - Z předešlých kapitol vše shrňte a uveďte, jak se data rozdělují, jak jsou replikována a jak konkrétně u Vašeho řešení probíhá celková distribuce dat pro zápis/čtení (např. jak Logstash/Beats zapisují, jak se dotazy směřují na shardy).
      - Uveďte řádný popis – textový popis + screeny + popis uvádějící například skript nebo konfiguraci, která provádí automatické rozdělení dat (pozor na příliš velkou výchozí velikost shardu/chunku), počty záznamů na jednotlivých uzlech (count), apod.
    - 1.2.8. Zabezpečení
      - Uveďte, jakým způsobem jste vyřešili zabezpečení ELK stacku a proč.
      - Minimálně je požadována autentizace a autorizace (např. použití uživatelských účtů, rolí, zabezpečení komunikace TLS mezi komponentami).
      - Uveďte řádný popis.
- **2. FUNKČNÍ ŘEŠENÍ**
  - Tato kapitola obsahuje popis a návod na zprovoznění funkčního řešení a popis jeho struktury.
  - 2.1. Struktura
    - Popište adresářovou strukturu Vašeho řešení a jednotlivé soubory, docker-compose.yml popište důkladně samostatně v kapitole 2.1.1.
  - 2.1.1. docker-compose.yml
    - Uveďte řádný popis vytvořeného docker-compose.yml – jaké služby spouští (Elasticsearch, Logstash, Kibana, případně Beats), jaké porty, volumes, proměnné prostředí, závislosti a inicializační skripty, atd.
  - 2.2. Instalace
    - Podrobně popište, jak zprovoznit Vaše řešení (kroky od stažení repozitáře po první přihlášení do Kibany a ověření, že data přitékají).
    - Řešení je nutné vytvořit tak, aby využívalo Docker a **spuštění probíhalo maximálně automatizovaně pomocí docker-compose.yml, tzn. že docker-compose.yml odkazuje na veškeré skripty, se kterými pracuje, a pro zprovoznění není nutné provádět manuální spuštění pomocných skriptů.**
    - V rámci **docker-compose.yml** využijte automatické spuštění skriptů poté, co se Vám spustí kontejnery (např. inicializační skripty pro vytvoření indexů, ingest pipelines apod.).
- **3. PŘÍPADY UŽITÍ A PŘÍPADOVÉ STUDIE**
  - Popište, pro jaké účely (případy užití) je ELK stack vhodný – např. centrální logování, monitorování, fulltextové vyhledávání, analýza událostí.
  - Uveďte, pro jaký konkrétní účel (případ užití) jste si ELK stack ve Vašem projektu zvolili a proč. K čemu Vaše řešení slouží? O jaký případ užití se jedná?
  - Uveďte, proč jste pro daný účel nezvolili jinou technologii (např. jinou NoSQL databázi, jiný log management nástroj).
  - Vyhledejte a popište 3 případové studie spojené s využitím ELK stacku nebo jeho jednotlivých komponent (Elasticsearch, Logstash, Kibana) v praxi.
  - **Rozsah každé případové studie musí být alespoň 1/2 A4**.
- **4. VÝHODY A NEVÝHODY**
  - Popište, jaké výhody a nevýhody má ELK stack jako celek z hlediska škálování, výkonu, správy a nároků na infrastrukturu.
  - Uveďte, jaké výhody a nevýhody má Vaše konkrétní řešení (konfigurace, architektura, datový model indexů) a proč.
- **5. DALŠÍ SPECIFIKA**
  - Popis specifických vlastností řešení, pokud jsou použita (např. specifické ingest pipeline, pokročilé analyzéry, ILM politiky, specifické vizualizace).
  - Pokud nejsou použita žádná specifika, pak uveďte, že Vaše řešení je použito tak, jak je doporučeno, a nemá vlastní specifika (nic mu nechybí a ani mu nic nepřebývá).
- **6. DATA**
  - Použijte libovolné 3 datové soubory (např. logové soubory, JSON události), kdy jeden soubor obsahuje alespoň 5 tisíc záznamů.Popis dat bude ve velké míře zpracován pomocí knihoven jazyka Python a dále bude doplněn dovysvětlujícími texty.
  - Jaká je distribuce shardů/chunků? - GET _cat/shards?v
  - Jaká je velikost shardů? - GET _cat/allocation?v
  - Jaký je replication lag? - GET _cat/recovery?v
  - Jaký je počet docs/velikost na shardu? - GET _cat/indices?v + GET index/_stats/docs
  - Uveďte:
    - S jakými typy dat Vaše řešení pracuje (např. logy webového serveru, aplikační logy), jakého jsou formátu a jak s nimi ELK stack nakládá.
    - Proč jste nezvolili jiné možné datové zdroje pro Vaše řešení.
    - S kolika daty Vaše řešení bude pracovat? Jakého rozsahu jsou ukázková data?
    - Kolik obsahují prázdných hodnot / chybějících polí?
    - Jaké úpravy jste s daty prováděli a proč (čištění, transformace, anonymizace)?
    - Jaký je zdroj dat? Uveďte URL adresu, případně popis generátoru dat.
    - Pomocí skriptů v Python s využitím knihoven Pandas, Numpy, apod. data popište a proveďte základní analýzu dat (základní statistiky – počty, prázdná pole, suma, průměr, grafické zobrazení, apod.).
- **7. DOTAZY**
  - Uveďte a popište 30 NETRIVIÁLNÍCH různých navazujících příkladů včetně řešení (všechny tři datasety popisují jedno téma) a podrobného vysvětlení jednotlivých příkazů.
    - NETRIVIÁLNÍ DOTAZ je v tomto kontextu netriviální vyhledávací dotaz nebo analytický dotaz nad Elasticsearch, využívající např. kombinaci bool dotazů, filtrování, agregací (terms, date_histogram, pipeline agregace), fulltextových analyzérů, scripted fields apod.
    - Příkazy řádně okomentujte, tzn., že každý dotaz (např. JSON DSL v Kibana Dev Tools) zkopírujete a u každého dotazu uvedete, jaké je jeho obecné chování a jak konkrétně pracuje s daty ve Vašem případě a řeší konkrétní úlohu.
    - Předpoklad je takový, že budete mít dotazy z různých kategorií, např.:
      - „práce s daty" – indexace, update_by_query, delete_by_query, reindex apod.,
      - „agregační funkce" – agregace typu terms, date_histogram, metrics (avg, sum, max), pipeline agregace,
      - „konfigurace" – dotazy související s nastavením indexů, analyzérů, mappingů,
      - „nested (embedded) dokumenty" – dotazy využívající nested typy, případně složité struktury dokumentů,
      - „indexy" – dotazy ilustrující práci s různými indexy, aliasy, přepínání indexů, apod.
    - Takových kategorií je požadováno alespoň 5, kdy u každé „kategorie" uvedete alespoň 6 příkazů.
    -
  - Každý dotaz musí vracet nějaká data.
  - **Každý dotaz musí vracet různá data. Nelze, aby stejná data vracelo více dotazů.**
  - Využijte možnosti práce s clusterem, replikací a shardingem (např. ukažte, jak se mění výsledek/latence při výpadku uzlu, jak se chová cluster při změně počtu shardů/replik).
  - Pokuste se například (mimo jiné) nasimulovat výpadek některého z uzlů a popište možnosti řešení (co se stane s dostupností dat, jak se cluster zotaví).
- **ZÁVĚR**
  - V závěru pochvalně i kriticky zhodnoťte Vaši semestrální práci, popište hloubku zpracování. Shrňte, k jakým závěrům jste došli, co je možné s Vaším řešením vykonávat, apod.
- **ZDROJE A NÁSTROJE**
  - Uveďte řádně všechny zdroje a nástroje, se kterými jste pracovali, abecedně seřazené, a to včetně použitých nástrojů (např. oficiální dokumentace Elastic, články, tutoriály, datasety).
- **PŘÍLOHY DOKUMENTACE**
  - **Data**
  - **složka** pojmenovaná Data, která obsahuje:
    - minimálně 3 datasety,
    - Python skript (např. Jupyter notebook), který provádí analýzu dat.
  - **Dotazy**
  - **složka** pojmenovaná Dotazy, která obsahuje:
    - 1 soubor se všemi dotazy, kdy každý dotaz obsahuje zadání v přirozeném jazyce a řešení v příslušném jazyce (DSL) pro Elasticsearch.
  - **Funkční řešení**
  - **složka** pojmenovaná Funkční řešení, která obsahuje:
    - docker-compose.yml,
    - skripty nutné pro zprovoznění (např. inicializační skripty, konfigurace Logstash pipeline),
    - případně další složky a soubory nutné pro zprovoznění řešení (konfigurační soubory, exporty dashboardů z Kibany, apod.).

Naposledy změněno: úterý, 17. března 2026, 16.31

◄ Podmínky zápočtu a zkoušky a hodnocení
Přejít na...
Důvody vedoucí k zamítnutí práce - binární kritéria ►